CIÊNCIA DE DADOS · UECE · 2026

Quais fatores estão associados à insatisfação dos clientes?

Da preparação dos dados ao modelo preditivo, com 95.824 pedidos do marketplace Olist

Profa. Ana Luiza Bessa de P. Barros · Equipe: Davi Alves, Silvio Gonçalves e Yago Melo

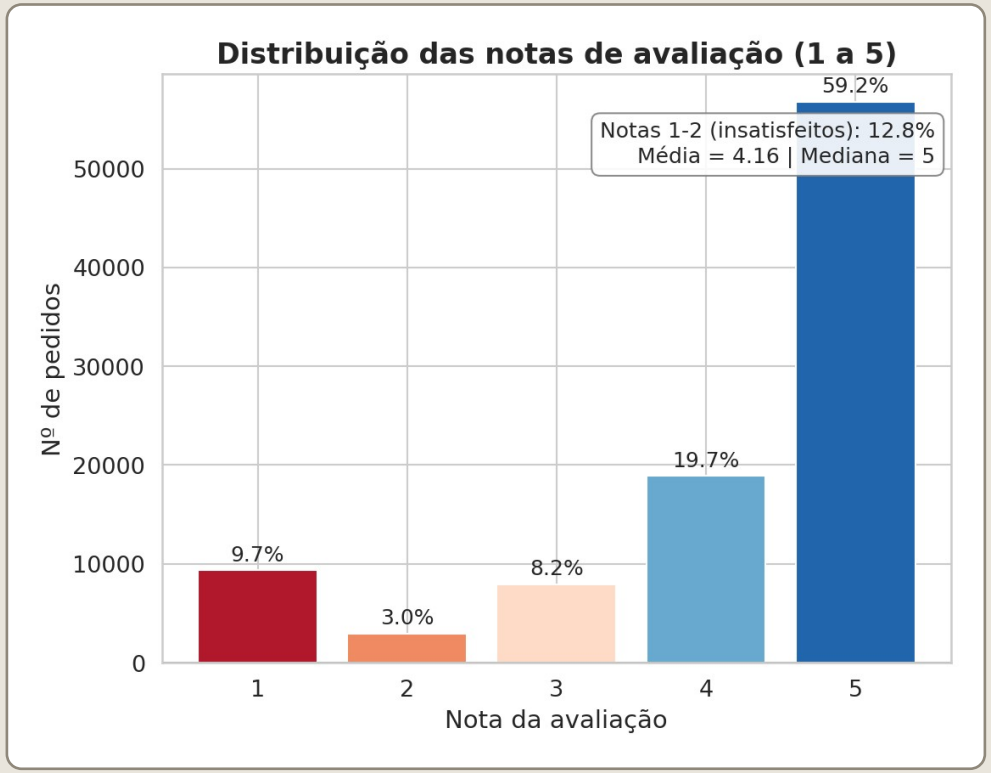
01 · LOAD

A base: 9 tabelas reduzidas a um pedido por linha

Recorte	Pedidos
Todos os pedidos	99.441
Status delivered	96.478
Com data de entrega	96.470
Com avaliação (base final)	95.824

Alvo: insatisfeito = nota ≤ 2

12,8% dos pedidos. Classe positiva minoritária: acurácia sozinha não basta.



Fonte: Kaggle olistbr/brazilian-ecommerce · reports/figures/fig01

02 · PREP

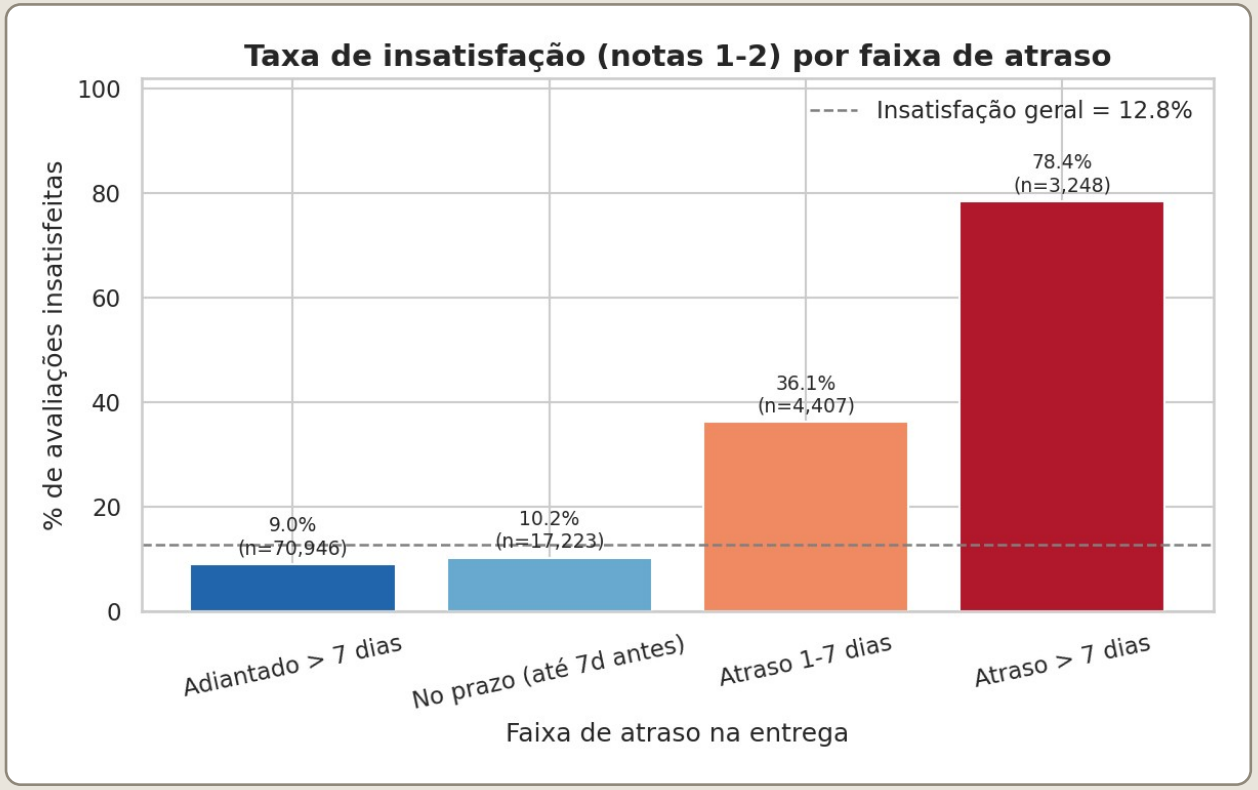
Cada transformação responde a um problema nos dados

Transformação	Problema que justifica	Resultado
Recorte analítico	Sem entrega ou avaliação não há alvo	99.441 → 95.824
Valores impossíveis → ausente	Datas incoerentes, peso e parcelas = 0	169 valores
Manter extremos coerentes	Fora de 3×IQR, mas plausíveis no domínio	ex.: entregas de 100+ dias
Remover variáveis derivadas	Identidades exatas (VIF > 1.000.000)	VIF máx. 2,7
Divisão 80/20 estratificada, antes de tudo	Teste não pode influenciar ajustes	76.659 / 19.165
Imputação mediana/moda no treino	Ausências residuais	2.026 células
One-hot, min_frequency = 30	Categóricas nominais, níveis raros	6 vars → 129 col.
z-score só para LR e PCA	Sensíveis à escala; árvores não	13 numéricas
Sem class_weight	Distorce probabilidades	limiar por CV: 0,22

Fonte: reports/relatorio_etapas.md, seção 2 · VIF em tab17_vif.csv

03 · EDA

A insatisfação dispara quando a entrega atrasa



78,4%

dos pedidos com atraso acima de 7 dias recebem nota 1 ou 2

Contra 9,0% adiantados

Só 8% dos pedidos atrasam, mas eles reúnem 34% dos insatisfeitos (4.138 de 12.262).

Fonte: reports/figures/fig04 · tab06_odds_ratio_atraso.csv

04 · TESTES

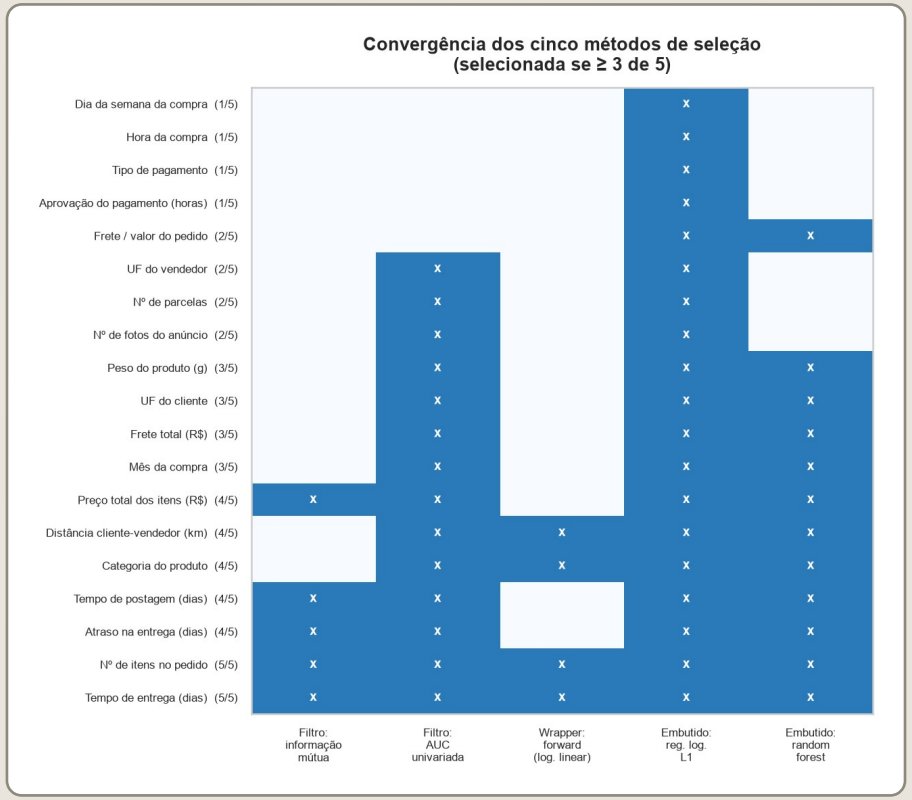
11,6×

mais chance de avaliação negativa quando o pedido atrasa (IC95% 11,0 a 12,2)

54,1% de insatisfeitos entre atrasados contra 9,2% no prazo · risco relativo 5,9× · qui-quadrado p < 0,001

05 · SELEÇÃO

Cinco métodos votam; ficam 11 de 19 variáveis



Corte por features-sombra

Cada variável disputa com cópias embaralhadas de si mesma; nenhum número fixo de variáveis.

Unânimes (5/5)

entrega_dias e n_itens. Maioria (3–4): atraso, manuseio, categoria, distância, preço, mês, frete, UF, peso.

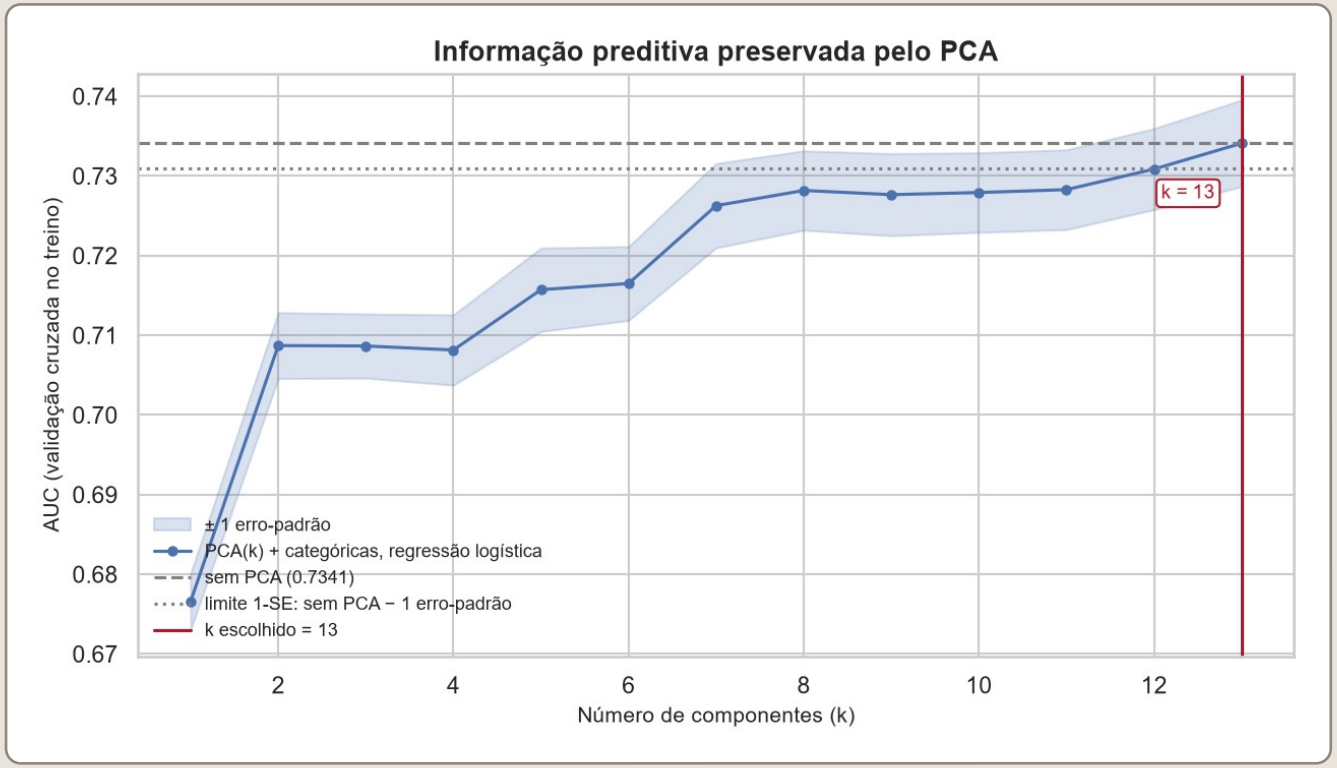
Descartadas (≤ 2/5)

pagamento, hora, dia da semana, aprovação, n_fotos, n_parcelas, frete_ratio, uf_vendedor.

Fonte: reports/figures/fig10 · tab12_ranking_features.csv

06 · PCA

Só k = 13 preserva a informação preditiva



k = 13 de 13

O PCA apenas rotaciona os eixos: nenhuma redução se justifica.

Custo da regra dos 90%

k = 10 baixaria o AUC de 0,734 para 0,728.

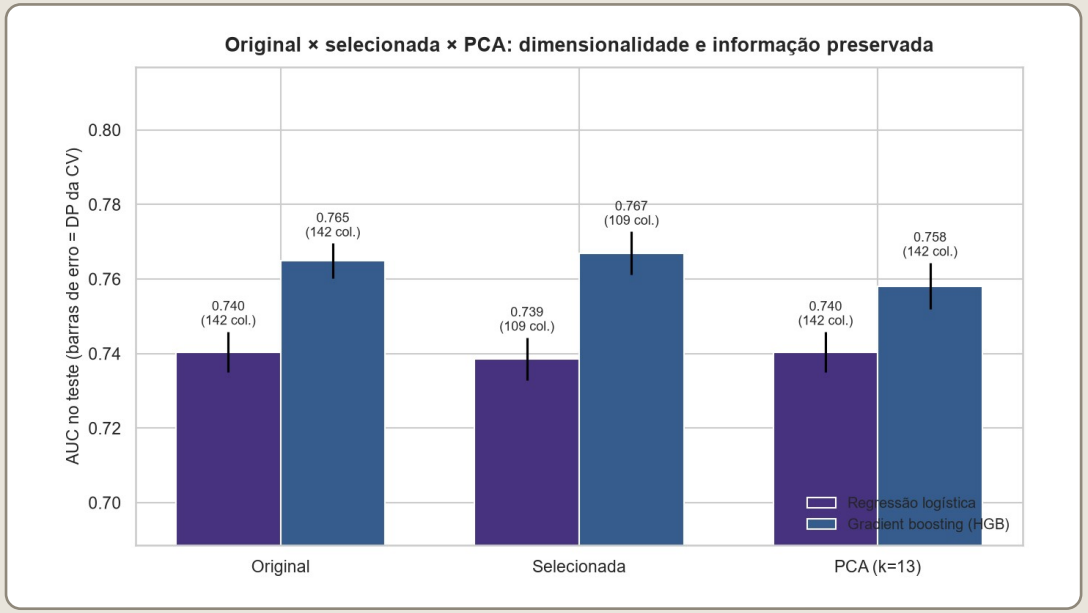
Critérios de variância divergem

Kaiser e análise paralela indicam 5; a regra dos 90%, 10. Parte do sinal está em componentes de baixa variância.

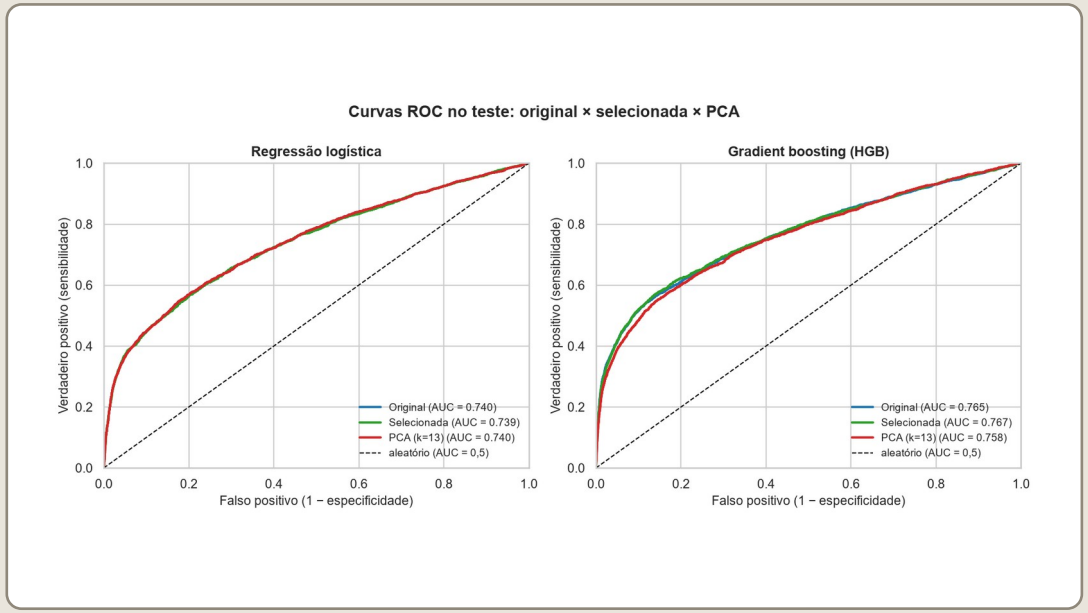
Fonte: reports/figures/fig13 · tab19_pca_cv.csv

08 · REDUÇÃO

Original × selecionada × PCA: a seleção não perde informação



Selecionada: 109 colunas, Δ AUC −0,0001 no boosting.



PCA (k = 13): mesmas 142 colunas, Δ −0,009 e menos interpretável.

Fonte: reports/figures/fig19 e fig20 · tab16_comparacao_representacoes.csv

SÍNTESE · PREPARAÇÃO E REDUÇÃO

Resposta: como preparar e reduzir preservando a informação?

PREPARAR

Regras de domínio, ajustes só no treino

Erros viram ausentes; extremos coerentes ficam; redundâncias exatas saem.

REDUZIR

Seleção por consenso: 19 → 11

Mesmo AUC da base original e variáveis ainda legíveis.

PCA

Aplicado, sem ganho

Só k = 13 preserva o sinal: rotação sem redução, com perda de leitura.

Fonte: reports/relatorio_etapas.md

09 · MODELOS

Protocolo: o teste é usado uma única vez

HOLDOUT

80/20 estratificado

76.659 treino · 19.165 teste · seed 42

→

TREINO

CV de 5 dobras

escolhe hiperparâmetros (AUC) e limiar (custo)

→

TESTE

Avaliação final

métricas, ROC, matrizes de confusão

Comparação justa

Mesmas dobras e semente para os 5 modelos; pré-processamento dentro do pipeline.

Estratificação

12,8% de positivos em cada dobra: sem ela, AUC e recall ficam instáveis.

Limiar por custo

Falso negativo custa 3× o falso positivo, em vez do padrão 0,5.

Fonte: reports/relatorio_modelos.md, seção 2

09 · MODELOS

Cinco famílias, uma busca em grade para cada

Modelo	Grade avaliada	Escolhido	AUC CV
Reg. logística (baseline)	C de 0,01 a 10 · 4 configs	C = 0,1	0,734
Árvore de decisão	critério, profundidade 3 a ∞, folha 20 a 200 · 56	gini, prof. 10, folha 200	0,743
KNN	k de 5 a 301, pesos, 19 ou 11 variáveis · 20	k = 301, distância, 11 var.	0,747
Gradient boosting (ensemble)	taxa 0,03 a 0,15, folhas 15/31, folha mín. 20/100 · 12	taxa 0,03, 31 folhas, mín. 20	0,760
MLP	alpha 0,0001 a 0,01, 3 arquiteturas · 9	alpha 0,001, (128, 64)	0,752

Árvore, KNN e boosting escolheram valores no limite da grade: pode haver configuração melhor fora dela.

Fonte: tab22_hiperparametros_avaliados.csv · tab23_hiperparametros_escolhidos.csv

09 · MODELOS

Tabela comparativa no teste: nenhum modelo lidera tudo

Modelo	Limiar	Acurácia	Precisão	Recall	F1	AUC (IC95%)
Regressão logística	0,25	0,874	0,508	0,374	0,431	0,741 [0,729–0,752]
Árvore de decisão	0,27	0,875	0,513	0,408	0,454	0,748 [0,736–0,760]
KNN	0,22	0,866	0,476	0,442	0,458	0,756 [0,746–0,767]
Gradient boosting ★	0,25	0,880	0,540	0,425	0,476	0,766 [0,754–0,778]
MLP	0,24	0,871	0,493	0,438	0,464	0,759 [0,748–0,770]
Classe majoritária	0,50	0,872	0,000	0,000	0,000	0,500

A acurácia engana

Prever “todos satisfeitos” acerta 0,872; dois modelos ficam abaixo disso.

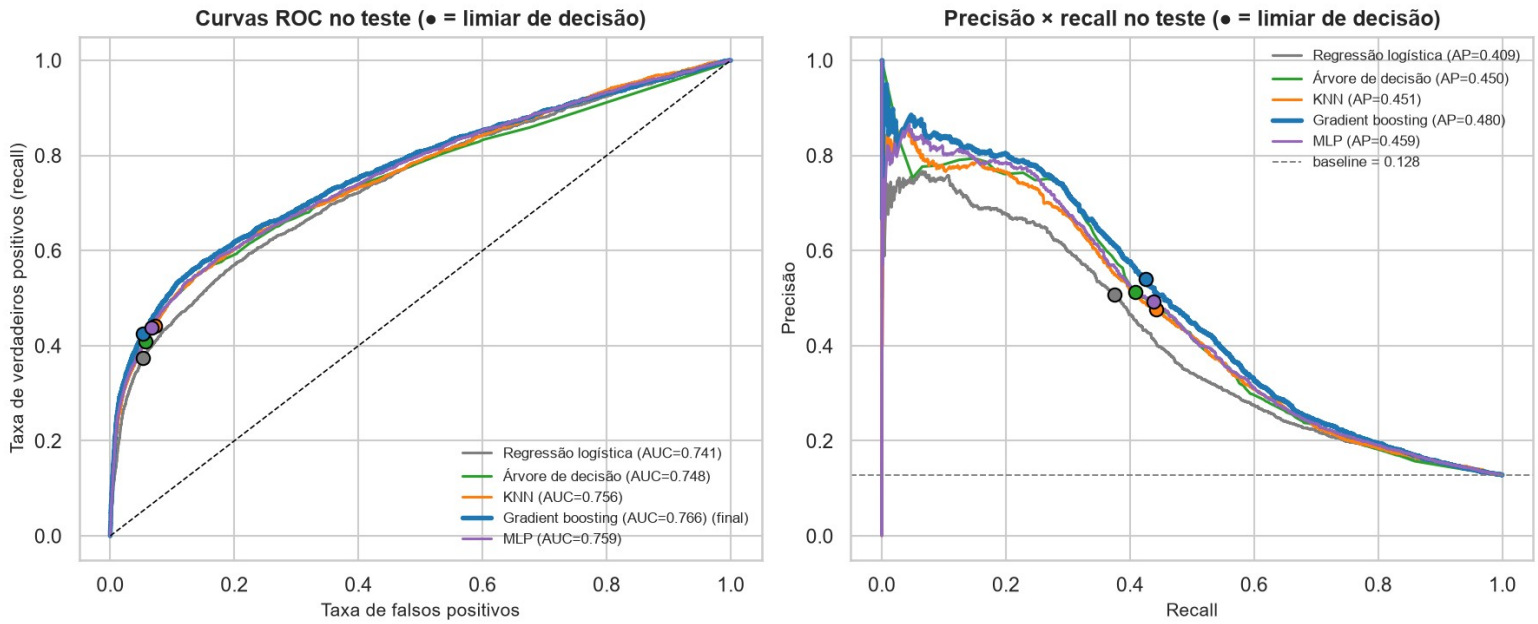
Líderes

Boosting: acurácia, precisão, F1 e AUC. KNN: recall (0,442).

Fonte: tab24_comparacao_modelos.csv · limiar de custo 3:1 · IC por bootstrap (300 reamostras)

09 · MODELOS

ROC e precisão × recall: curvas próximas, boosting à frente

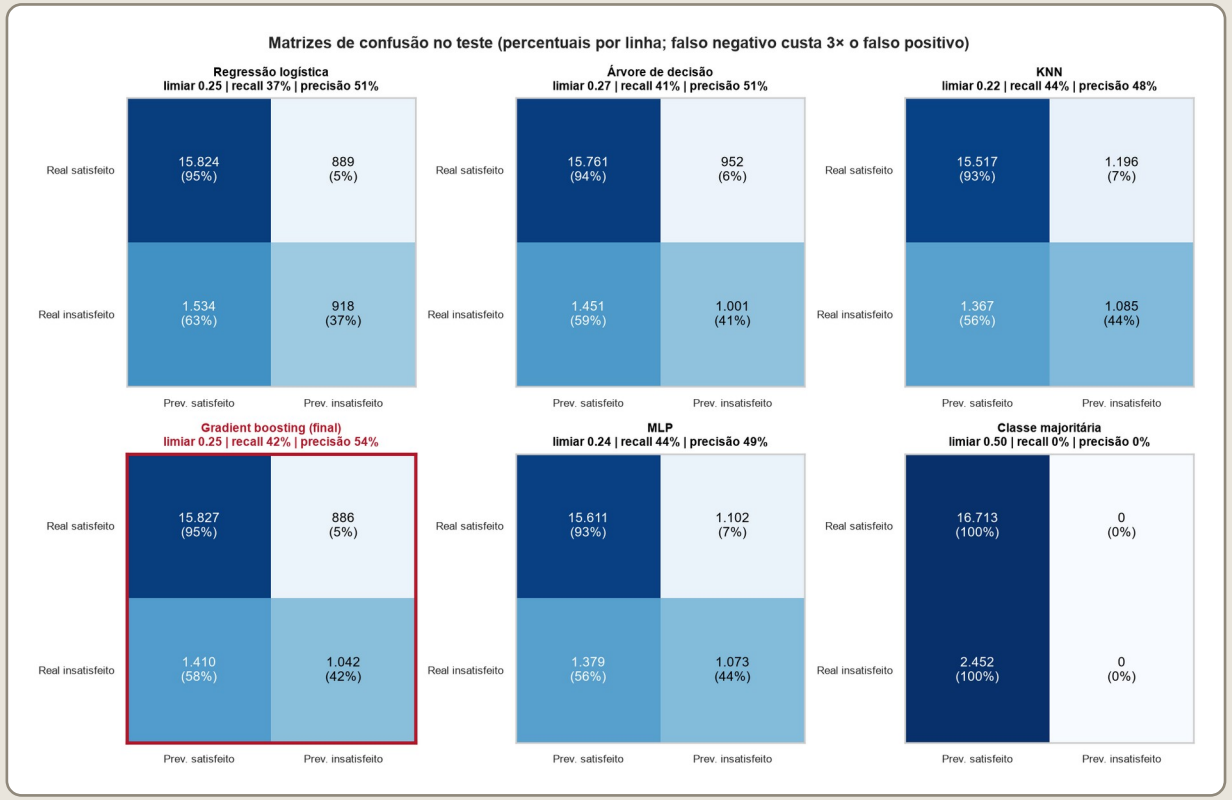


AUCs entre 0,741 e 0,766: o teto parece vir da informação nas variáveis, não do algoritmo. As diferenças para o boosting são significativas, mas pequenas.

Fonte: reports/figures/fig21 · tab27_diferenca_auc_vs_final.csv

09 · MODELOS

Matrizes de confusão: quem erra o quê



Menos falsos negativos

KNN: 1.367 insatisfeitos perdidos, à custa de 1.196 contatos desnecessários.

Menos falsos positivos

Boosting: 886 contatos desnecessários, 0,9 por acerto.

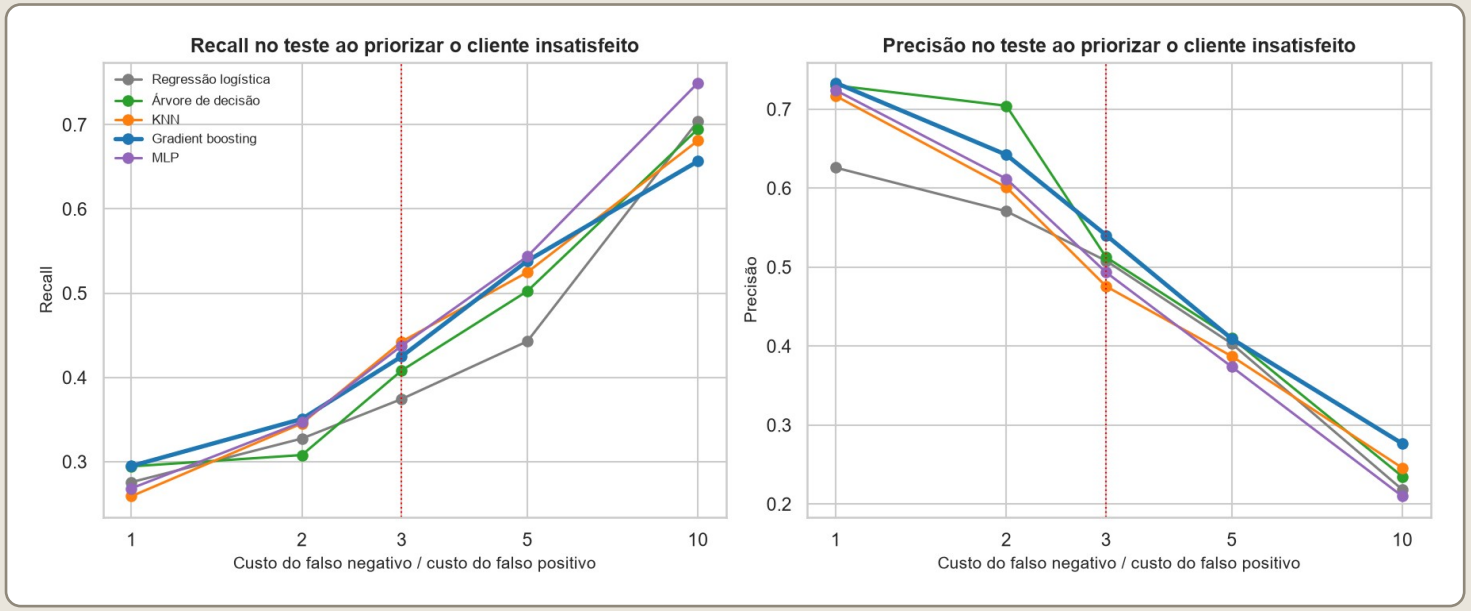
Limite comum

Todos perdem mais da metade dos insatisfeitos: 1.367 a 1.534.

Fonte: reports/figures/fig22 · tab25_limiares_e_erros.csv

09 · MODELOS

Precisão × recall depende de quanto pesa o falso negativo



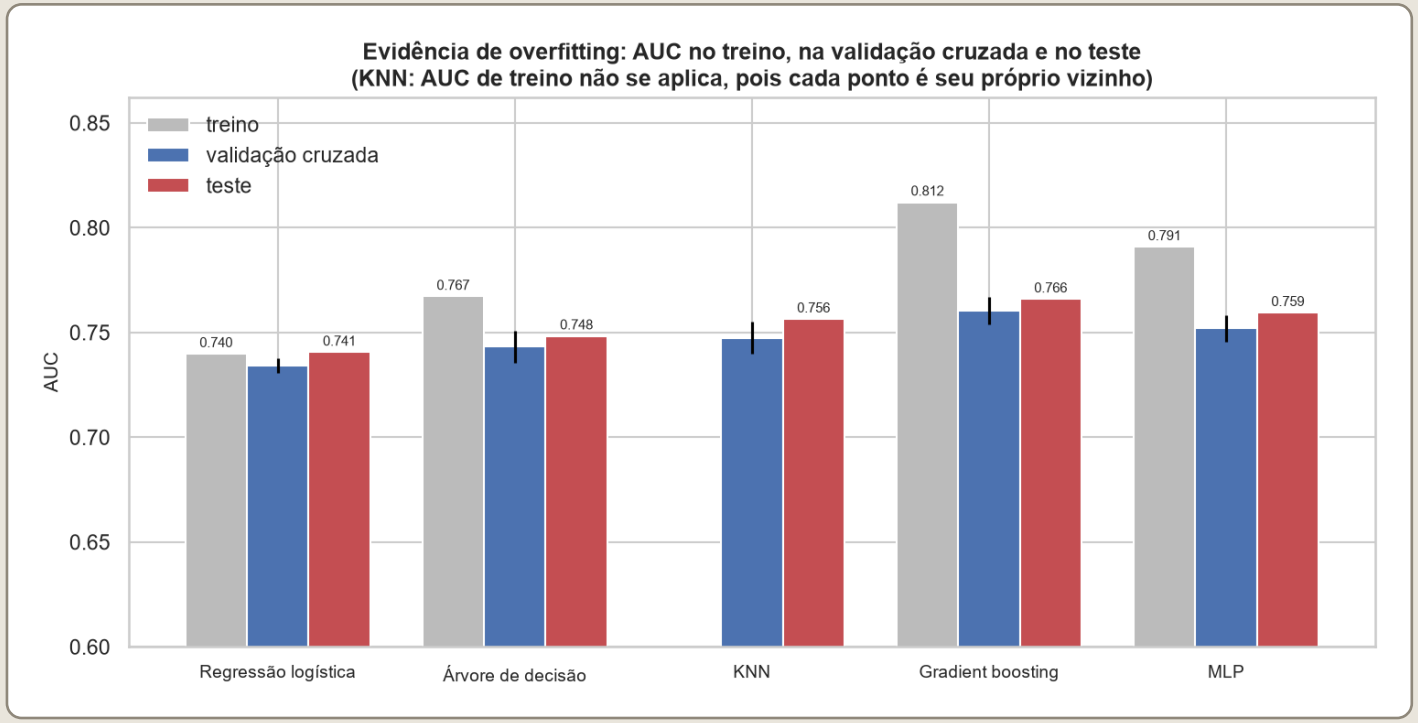
FN / FP	Recall	Precisão
1×	0,29	0,73
3× (adotado)	0,42	0,54
10×	0,66	0,28

Valores do boosting. A razão 3:1 é premissa: com custos reais, o limiar muda.

Fonte: reports/figures/fig27 · tab26_sensibilidade_custo.csv

09 · MODELOS

Os resultados da validação se mantêm no teste



CV → teste

Diferença máxima de 0,009: nenhum modelo perde desempenho no teste.

Treino > CV

Boosting (+0,052) e MLP (+0,039): esperado em modelos flexíveis, sem prejuízo no teste.

KNN

AUC de treino não se aplica: cada ponto é o próprio vizinho.

Fonte: reports/figures/fig25 · Fonte: reports/relatorio_modelos.md, seção 4.6

09 · MODELOS

Vantagens e limitações observadas nos resultados

Modelo	Vantagens	Limitações observadas
Reg. logística	simples, rápida, odds ratio	linear: não capta o limiar do atraso
Árvore	regras legíveis, capta limiares	instável; overfitting sem limite
KNN	poucos hiperparâmetros	exige k alto, lento (4,3 s), sem interpretação
Gradient boosting	melhor equilíbrio desempenho/custo	menos interpretável: exige SHAP
MLP	flexível, predição rápida	varia com a semente (0,751–0,760)

Fonte: reports/relatorio_modelos.md, seção 4.8

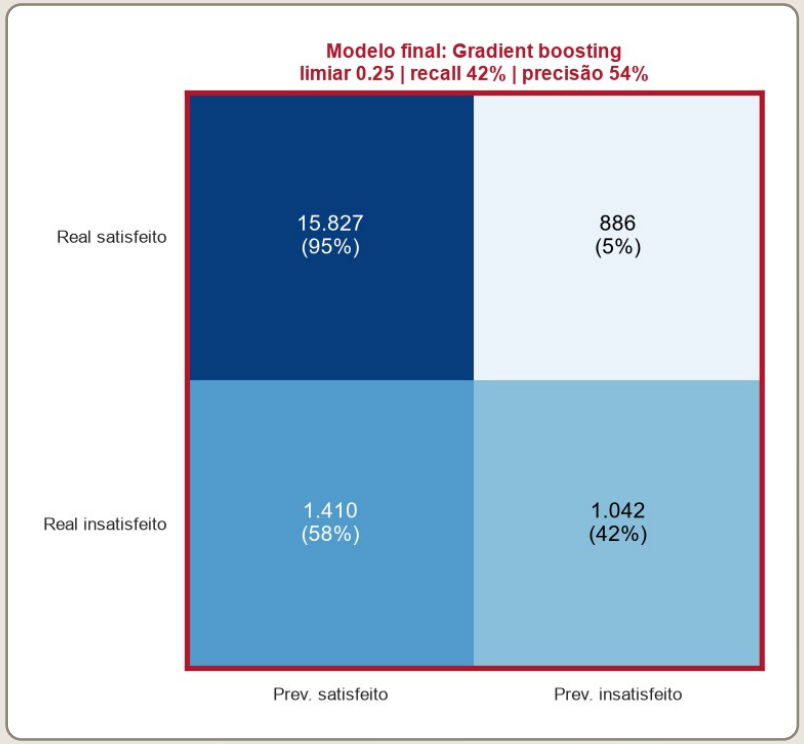
SÍNTESE · MODELOS SUPERVISIONADOS

Resposta: o gradient boosting é o modelo mais adequado

Critério definido antes do teste

Maior AUC de CV; empates a 1 erro-padrão decididos pelo menor custo. Só o boosting ficou nessa faixa.

Evidência	Valor
AUC CV · teste	0,760 · 0,766
Recall · precisão	0,425 · 0,540
Custo médio (FN = 3×FP)	0,267, o menor
Custo vs. não agir	−30,5%



Fonte: reports/relatorio_modelos.md, seção 5 · reports/figures/fig23

LIMITAÇÕES E PRÓXIMOS PASSOS

O que pode mudar a conclusão

Limitações

- Associação, não causalidade: base observacional
- Alvo definido pela equipe (nota ≤ 2)
- Modelo principal usa o atraso realizado
- Unificação de categorias é hipótese de domínio
- Custo 3:1 é premissa, não custo real

Próximos passos

- Grades mais finas onde o valor ficou no limite
- CV com várias sementes e corte temporal
- Agrupar categorias e UFs para reduzir o one-hot
- FAMD para dados mistos; seleção dentro da CV

Fonte: reports/relatorio_etapas.md, seção 7 · relatorio_modelos.md, seção 6

OBRIGADO

O prazo de entrega é a alavanca da satisfação

PRAZO

Priorizar o prazo prometido

Alertar pedidos com risco de atraso

PEDIDO

Investigar pedidos com 2+ itens

Hipótese: envios fracionados

SCORE

Contato preventivo

Usar a probabilidade do modelo final

Perguntas?

Código e relatórios: Data-Science-Class-Project (pipeline e notebooks)

APÊNDICE

Material de apoio para perguntas

Roteiro do pipeline, diagnóstico, EDA e testes detalhados, seleção e PCA, SHAP, validações extras, ensemble, vantagens dos modelos, recomendações e dicionário

ROTEIRO

Treze etapas, executáveis por pipeline ou notebook

01
load
9 tabelas → 1 linha por pedido

02
prep
qualidade, regras, treino/teste

03
eda
notas, atraso, categorias, UF

04
testes
efeito + p ajustado (Holm)

05
seleção
filtro, wrapper, embutido

06
PCA
Kaiser, paralela, CV preditiva

07
model
logística × boosting, SHAP

08
redução
original × seleção × PCA

09
modelos
5 famílias, CV e custo

10
etapas
relatório de preparação

11
relatório
achados e ações

12
rel. modelos
escolha do modelo final

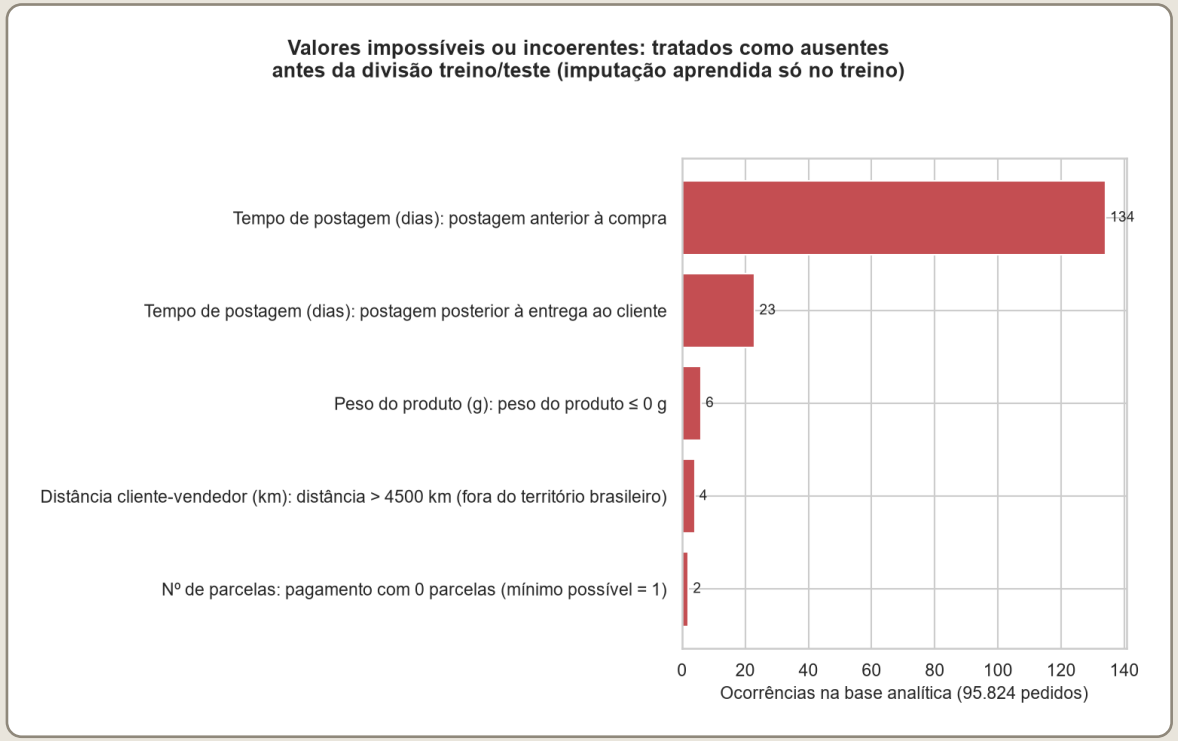
13
dicionário
tabelas e features

2 FORMAS
pipeline + notebook
mesmo código de src/, seed 42

Pipeline: run_pipeline.py · Notebooks: analise_preprocessamento_reducao.ipynb e pipeline_completo.ipynb

02 · PREP

Diagnóstico: separar erro de valor extremo legítimo



169 valores impossíveis

Postagem antes da compra, 0 parcelas, peso 0 g, distância fora do Brasil: viram ausentes antes da divisão.

Extremos coerentes mantidos

Fora de 3×IQR e checados pelo domínio: entregas de 100+ dias combinam com atraso e nota baixa.

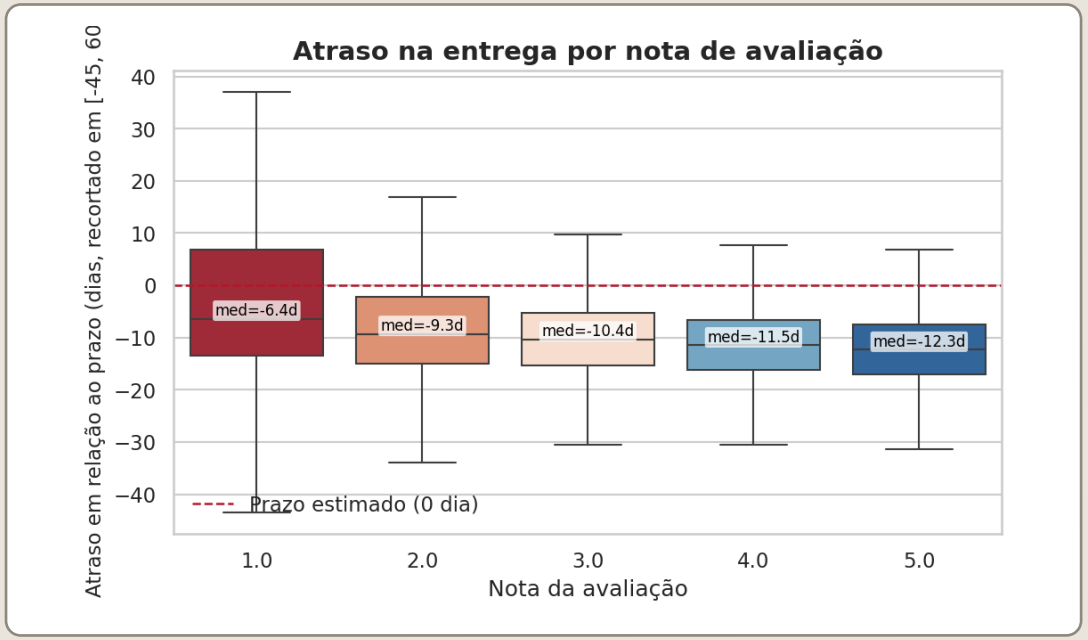
22 colunas descartadas

Identificadores, constante, engenharia de datas, redundância e vazamento (review).

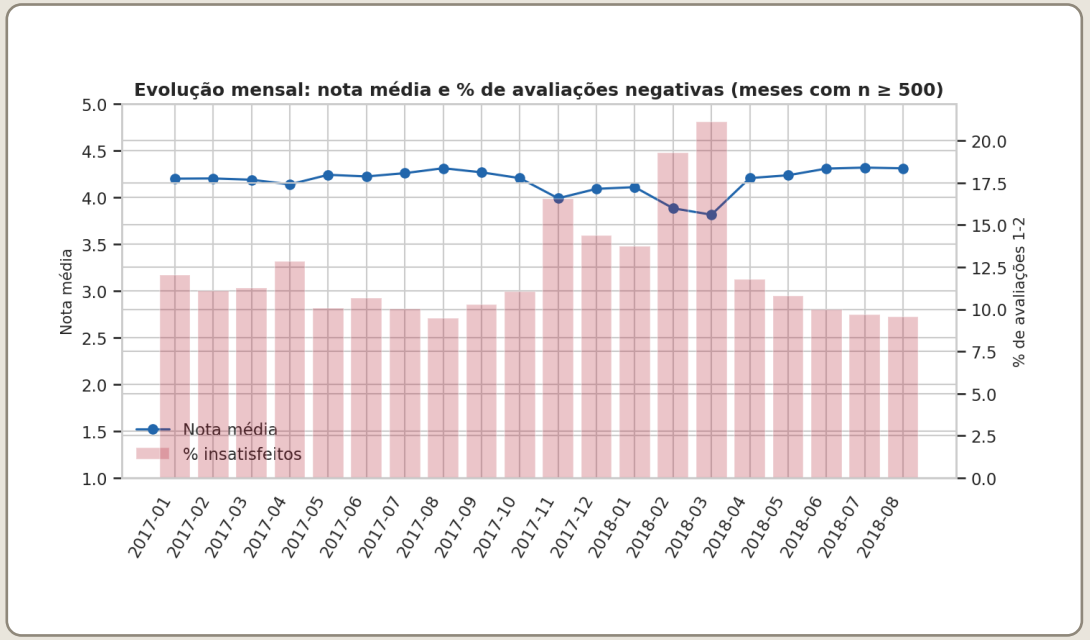
Fonte: reports/figures/fig11 · tab15_diagnostico_qualidade.csv

03 · EDA

Nota cai com o atraso, e há um pico em fev–mar/2018



Mediana de atraso: −6,4 dias na nota 1 contra −12,3 na nota 5. Prazos folgados protegem a nota.

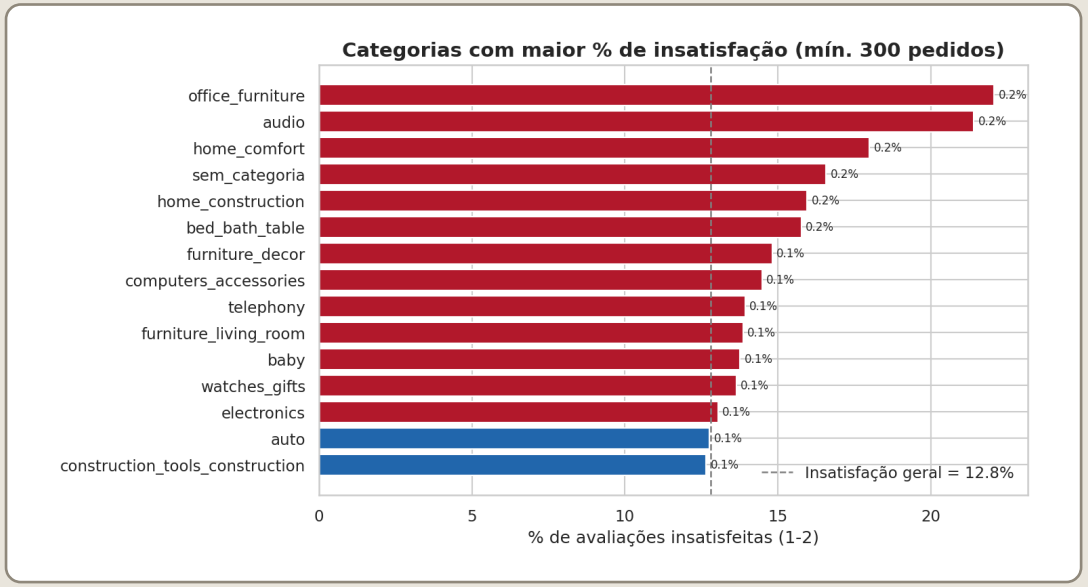


Insatisfação passa de 20% em mar/2018: evento pontual que o modelo captura via mes_compra.

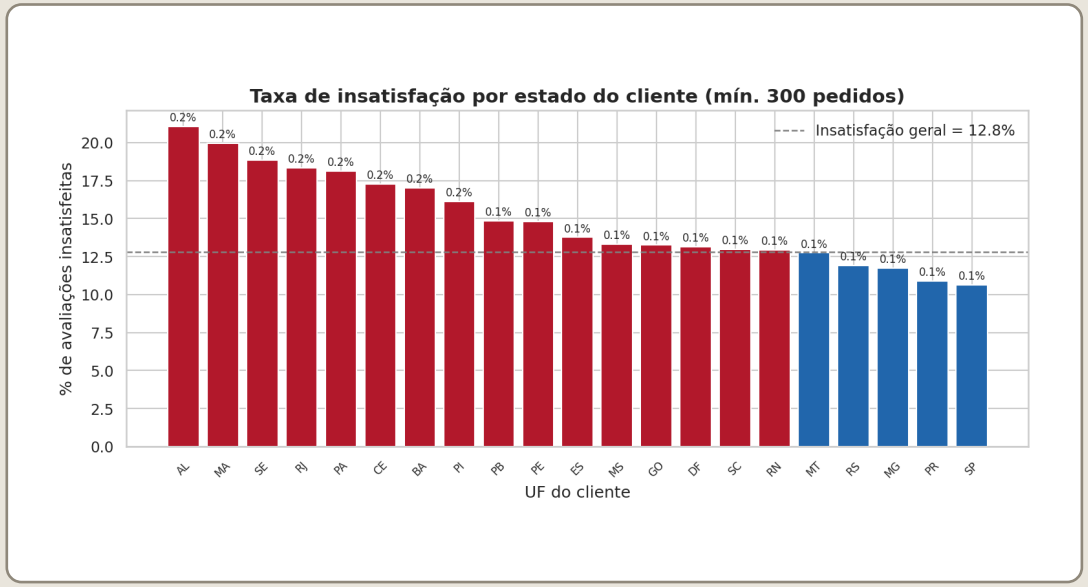
Fonte: reports/figures/fig03 e fig02

03 · EDA

Categorias e estados também variam, com menos força



office_furniture 22,1% e audio 21,4%, contra 12,8% no geral (mín. 300 pedidos).



AL 21,1%, MA 19,9% e RJ 18,4% (12.211 pedidos); SP e PR abaixo da média.

Fonte: reports/figures/fig05 e fig06 · tab03 e tab04

04 · TESTES

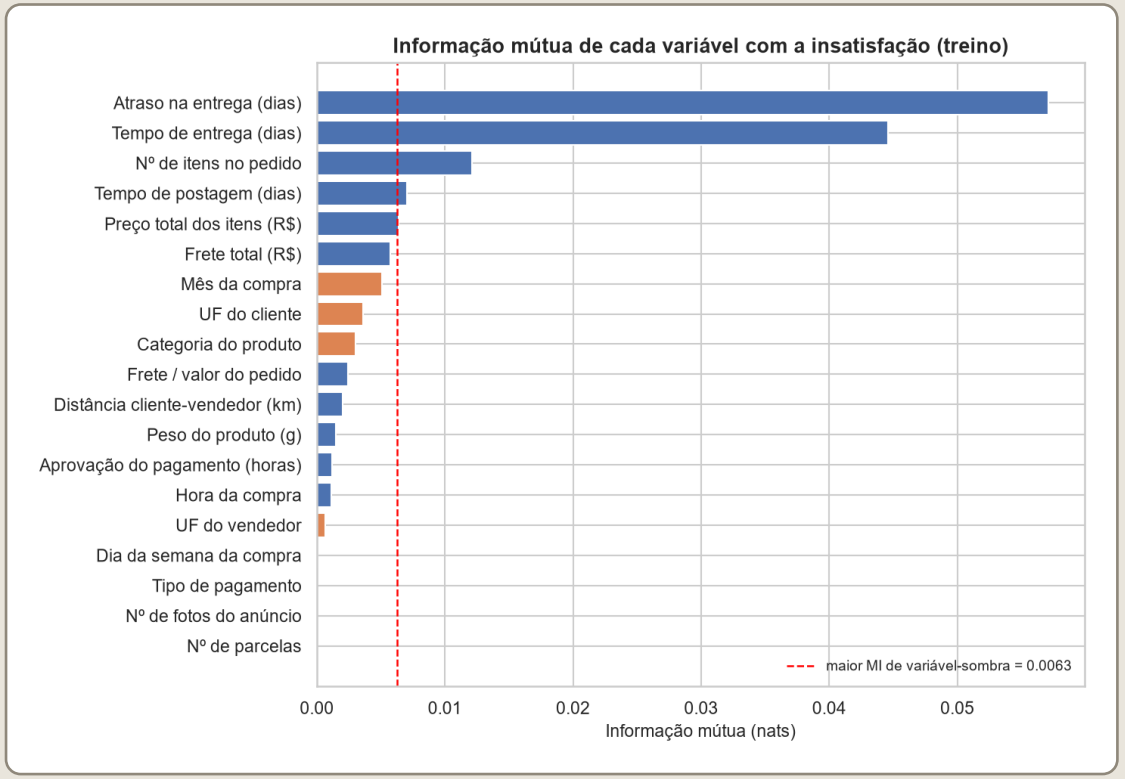
Com 95 mil pedidos, o tamanho do efeito decide

Teste	Comparação	Efeito	p (Holm)
Qui-quadrado	Faixa de atraso × insatisfação	V = 0,40	< 0,001
Mann-Whitney	Tempo total de entrega	r = 0,37	< 0,001
Qui-quadrado	Prazo cumprido × insatisfação	V = 0,36	< 0,001
Mann-Whitney	Atraso (dias)	r = 0,31	< 0,001
Mann-Whitney	Tempo até a postagem	r = 0,17	< 0,001
Mann-Whitney	Frete total	r = 0,16	< 0,001
Qui-quadrado	UF do cliente	V = 0,09	< 0,001
Qui-quadrado	Categoria do produto	V = 0,07	< 0,001
Qui-quadrado	Forma de pagamento	V = 0,008	0,094

Fonte: reports/tables/tab05_testes_hipotese.csv · 19 testes, p ajustado por Holm

05 · SELEÇÃO

Filtro, wrapper e embutido enxergam coisas diferentes



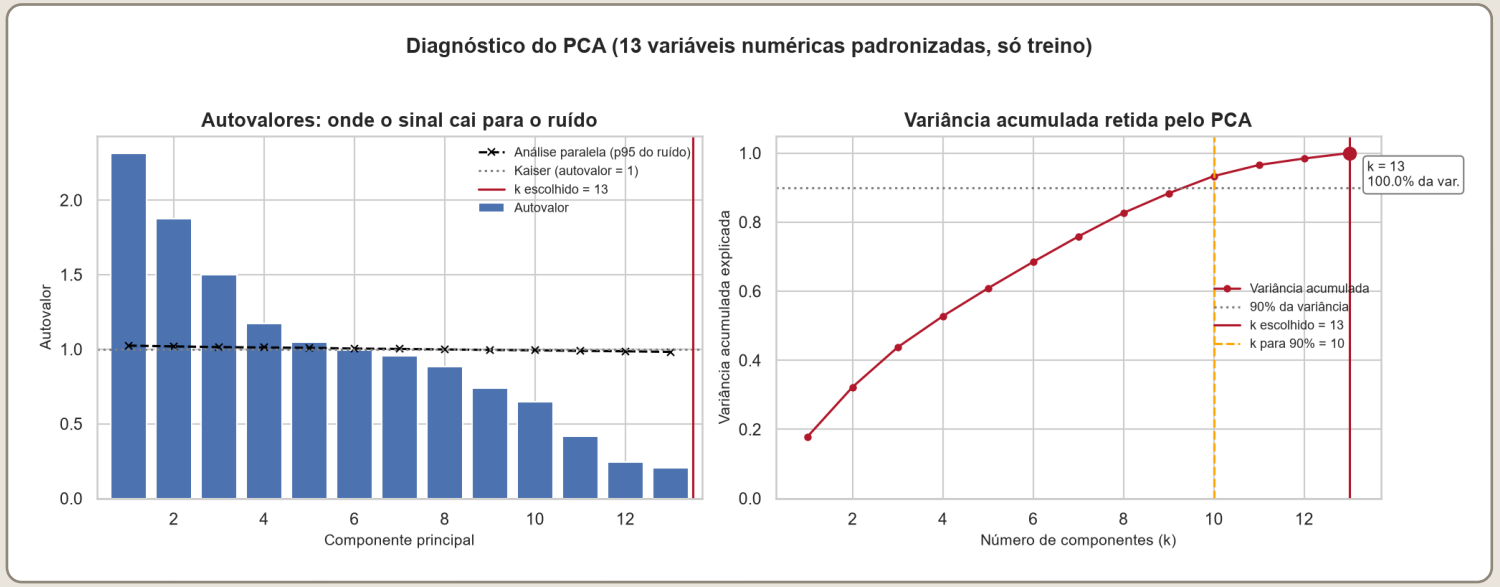
Método	Selecionadas
Filtro: informação mútua	5
Filtro: AUC univariada	14
Wrapper: forward (LR)	4
Embutido: L1	19
Embutido: random forest	12

Wrapper custou 85 ajustes (18 s). L1 manteve todas: a seleção efetiva vem dos outros quatro.

Fonte: reports/figures/fig09 · relatorio_etapas.md, seção 3

06 · PCA

Quantas componentes? Os critérios de variância divergem



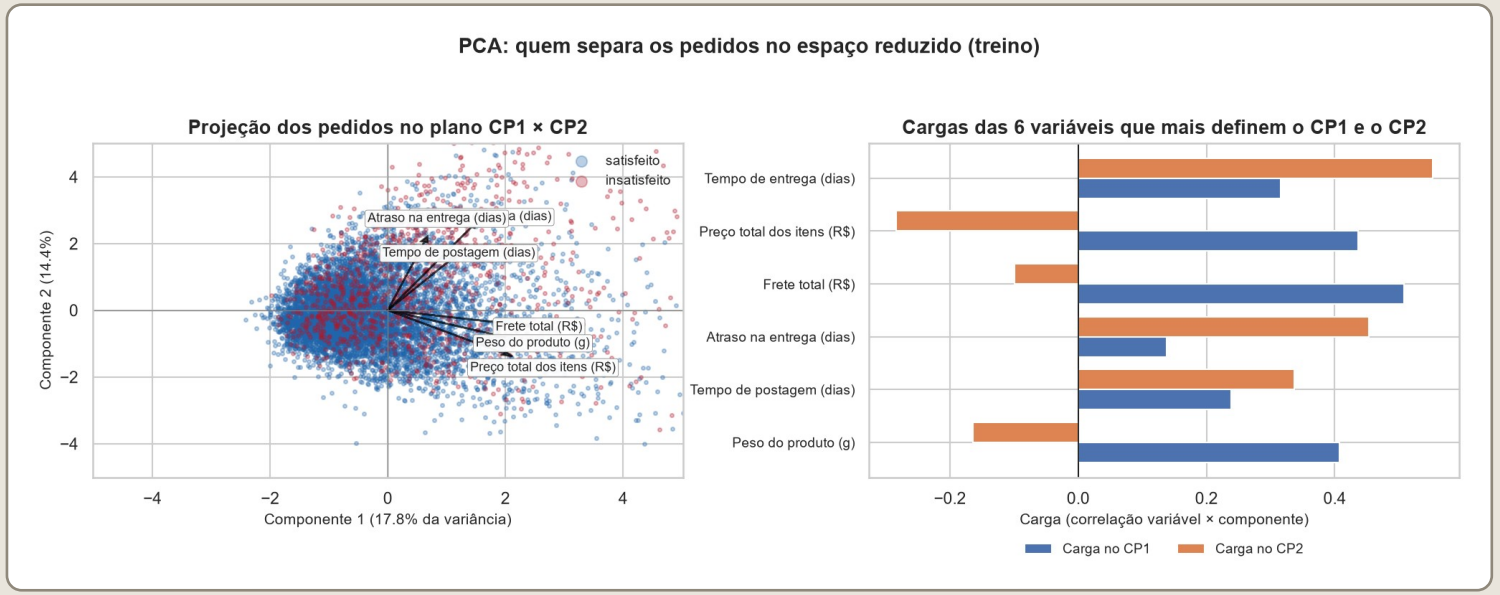
Critério	k
Kaiser (autovalor > 1)	5
Análise paralela	5
90% da variância	10
CV preditiva (1 EP)	13

PCA no treino, sobre as 13 numéricas padronizadas.

Fonte: reports/figures/fig12 · tab13_pca_variancia.csv, tab14

06 · PCA

As componentes misturam variáveis e não separam as classes



CP1 · custo e tamanho

Frete, preço e peso. AUC isolada 0,666.

CP2 · logística

Entrega, atraso e postagem. AUC isolada 0,639.

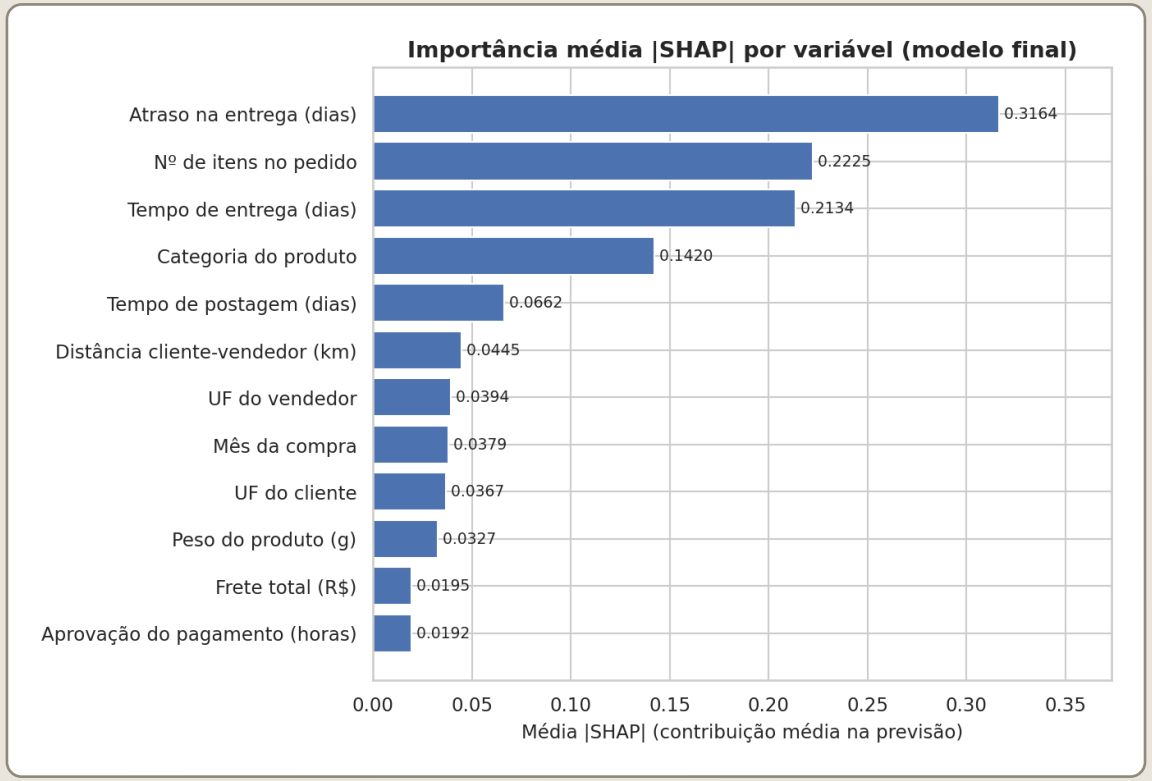
Nuvem única

Satisfeitos e insatisfeitos se sobrepõem: o PCA não usa o alvo.

Fonte: reports/figures/fig14 · tab18_pca_cargas.csv

07 · MODEL

O que o modelo aprendeu: o prazo domina



Grupo de variáveis	Queda de AUC
Prazo e tempo de entrega	0,196
Pedido: itens, preço, frete	0,062
Produto	0,017
Geografia	0,007
Calendário	0,001
Pagamento e aprovação	0,001

Permutar o grupo inteiro evita dividir o crédito entre atraso e entrega.

Modelo da etapa model (HGB, taxa 0,08) · Fonte: reports/figures/fig15 · tab20_importancia_grupos.csv

07 · MODEL

Robustez: o desempenho cai fora do cenário ideal

0,766

Teste aleatório

cenário principal

0,690

Validação temporal

treina no passado, testa nos 20% mais recentes

0,692

Modelo pré-entrega

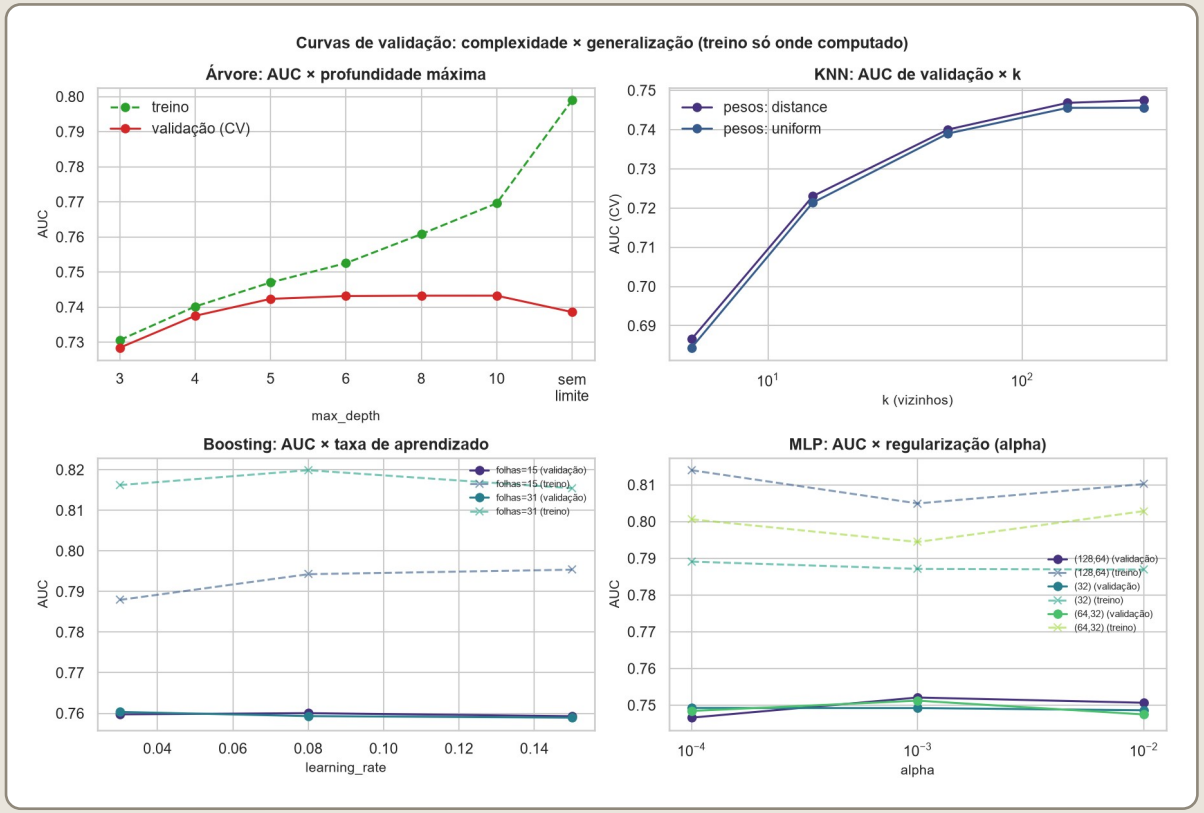
sem atraso_dias e entrega_dias

Para agir antes da entrega, o score é mais fraco: dados de rastreio ajudariam.

Fonte: outputs/resultados_modelo.json · validacoes_adicionais (AUC)

09 · MODELOS

Complexidade × generalização: as curvas de validação



Árvore

Treino sobe até 0,80 sem limite de profundidade; a CV estaciona em 0,743. Limitar profundidade e folha evita overfitting.

KNN

AUC cresce com k até 301: decisões locais são ruidosas com 142 colunas.

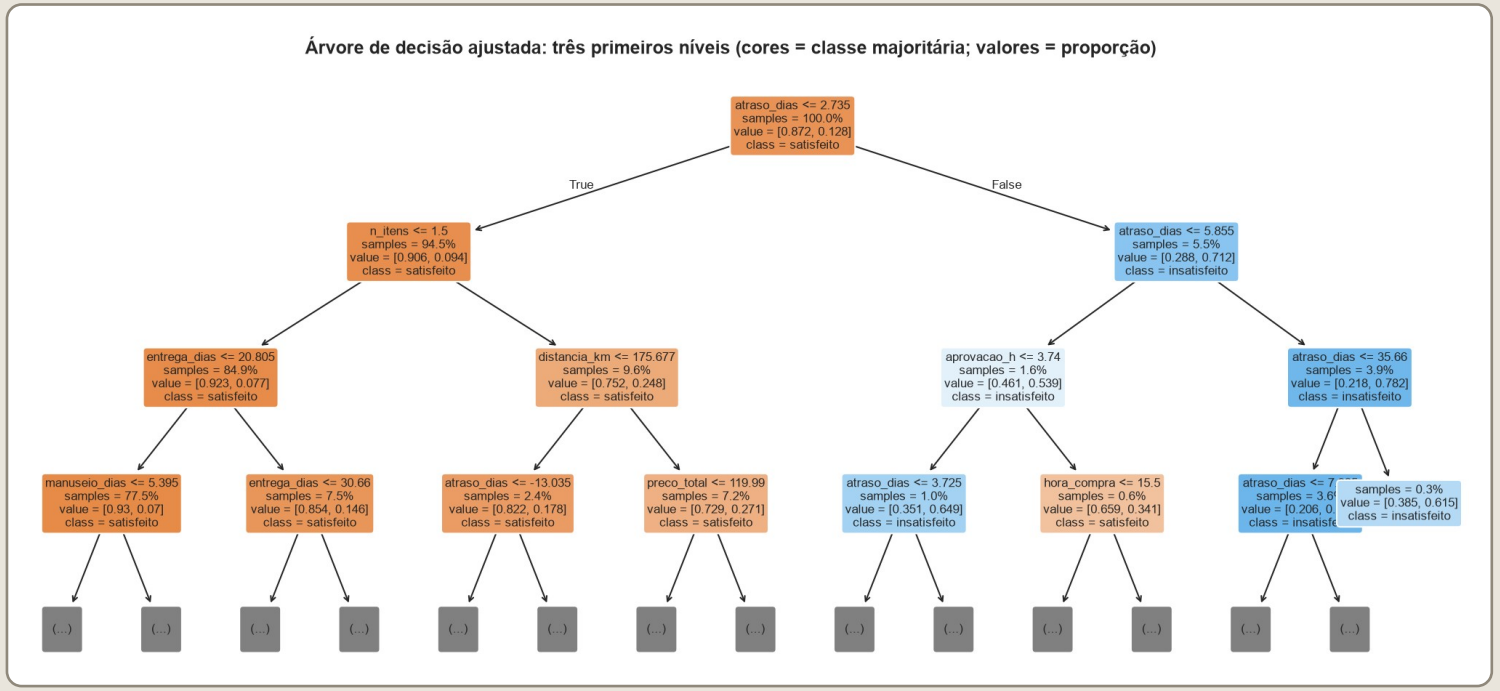
Boosting e MLP

Curvas quase planas: pouco sensíveis aos hiperparâmetros testados.

Fonte: reports/figures/fig24

09 · MODELOS

O ensemble supera a árvore, mas perde as regras legíveis



Métrica	Árvore	Boosting
Precisão	0,513	0,540
Recall	0,408	0,425
F1	0,454	0,476
AUC	0,748	0,766

Primeiro corte da árvore: atraso acima de 2,7 dias, o mesmo achado da EDA.

Fonte: reports/figures/fig26 · Fonte: reports/relatorio_modelos.md, seção 4.7

11 · RELATÓRIO

Da evidência à ação

Achado	Evidência	Ação sugerida
Atraso na entrega	OR 11,6×; queda de AUC 0,196	Priorizar o prazo prometido e alertar pedidos em risco
Pedidos com 2+ itens	26,8% contra 11,3%	Investigar envios fracionados (hipótese)
Categoria e UF	office_furniture 22%; RJ 18%	Acompanhar por segmento
Frete e distância	$\|r\| \leq 0,16$	Efeito pequeno: não é a alavanca principal
Forma de pagamento	$p = 0,094$	Sem associação: não priorizar

Fonte: reports/relatorio.md · README, resultados principais

Apêndice: as 19 features candidatas

Feature	Significado
atraso_dias	Entrega real − prometida (dias)
entrega_dias	Compra até entrega (dias)
manuseio_dias	Compra até postagem (dias)
aprovacao_h	Compra até aprovação (horas)
n_itens	Nº de itens no pedido
preco_total	Soma dos preços (R$)
frete_total	Soma dos fretes (R$)
frete_ratio	Frete / valor do pedido
distancia_km	Distância cliente–vendedor
peso_g	Peso do produto (g)

Feature	Significado
n_fotos	Fotos do anúncio
n_parcelas	Parcelas do pagamento
hora_compra	Hora da compra
dia_semana_compra	Dia da semana
mes_compra	Mês da compra
categoria_grupo	Categoria do produto
uf_cliente	Estado do cliente
uf_vendedor	Estado do vendedor
pagamento_tipo	Forma de pagamento

Dicionário completo, com as tabelas brutas: reports/dicionario_dados.md